

Технология хранения и архитектура больших данных

П. В. Купцов. Факультет КНиИТ СГУ, кафедра ИиП

ПРАКТИЧЕСКИЕ ЗАНЯТИЯ

Предварительная информация

Все задания в этом курсе выполняются с использованием контейнеров docker, конфигурируемых и запускаемых при помощи docker compose. Убедитесь что Docker установлен.

Для этого в Windows или MacOS нужно скачать и установить Docker Desktop
<https://docs.docker.com/get-started/get-docker/>.

Далее, для работы с контейнерами Docker в Windows или MacOS потребуется запускать приложение Docker Desktop.

Под Linux Docker можно установить из репозитория. При этом будет установлен и запущен сервис, который обеспечивает работу Docker. В дальнейшем можно просто работать с контейнерами не запуская предварительно никаких дополнительных приложений.

Справочная информация: некоторые команды управления контейнерами, выполняются в консоли.

Запустить контейнер в фоновом режиме: в консоли перейти в папку с файлом «docker-compose.yaml» и выполнить

- `docker compose up -d`

Получить список запущенных контейнеров:

- `docker ps`

Остановить контейнеры: находясь в консоли в той же папке, что и при запуске, выполнить

- `docker compose down`

Принудительное завершение контейнера: выполнить команду ниже, вместо <NAME> ввести имя, которое показывает команда `docker ps` в последнем столбце.

- `docker kill <NAME>`

Выполнить команду в запущенном контейнере (в примере в контейнере `mysql_db` запускается оболочка bash и мы получаем возможность работать с файловой системой контейнера):

- `docker compose exec mysql_db bash`

Если перед запуском контейнеров выполняется установка дополнительных пакетов при помощи опции `build` и `Dockerfile`, то при необходимости пересобрать контейнеры (например, при изменении `Dockerfile`) можно следующей командой:

- `docker compose build --no-cache`

Логи, которые контейнер пишет в консоль можно посмотреть при помощи следующей команды. Помогает, например, когда контейнер падает.

- `docker logs <NAME>`

Очистка неиспользуемых ресурсов контейнеров и удаление не используемых в данный момент анонимных томов:

- `docker system prune --volumes`

Удаление всех томов, в том числе именованных. Все сделанные в контейнерах изменения будут удалены, за исключением тех, которые сохранялись в подмонтированных каталогах.

- `docker volume prune --all`

Удаление всех контейнеров из локального репозитория (после этого при запуске контейнеров будет автоматически запущено их скачивание):

- `docker system prune --all`

Удаление именованных томов, созданных контейнерами. Если удалить том, то все изменения, сделанные при работе с контейнером буду потеряны (если данные контейнера сохранялись в этом томе).

- `docker volume rm <NAME>`

Внимание! Если при попытке запуска контейнера появляется ошибка «Error response from daemon: failed to set up container networking» то это значит что на локальном компьютере занят порт, на который должен отображаться порт сервера, запускаемого в контейнере. В этой ситуации нужно сначала выполнить полную выгрузку упавшего контейнера `docker compose down`, а затем поменять настройку порта локального компьютера (хоста) в разделе `ports` файла `docker-compose.yaml`.

Задание 1. SQL

Скачайте и установите DBeaver Community Edition (бесплатную версию) с сайта <https://dbeaver.io/>.

Скачайте и распакуйте архив `bigd_course_mysql_jupyter.zip` в своей рабочей папке.

Откройте в простом текстовом редакторе, типа Блокнота, конфигурационный файл `docker-compose.yaml`. Изучите его структуру и содержание. В этом Вам поможет файл `docker-compose-template.yaml` и документация по `docker compose`.

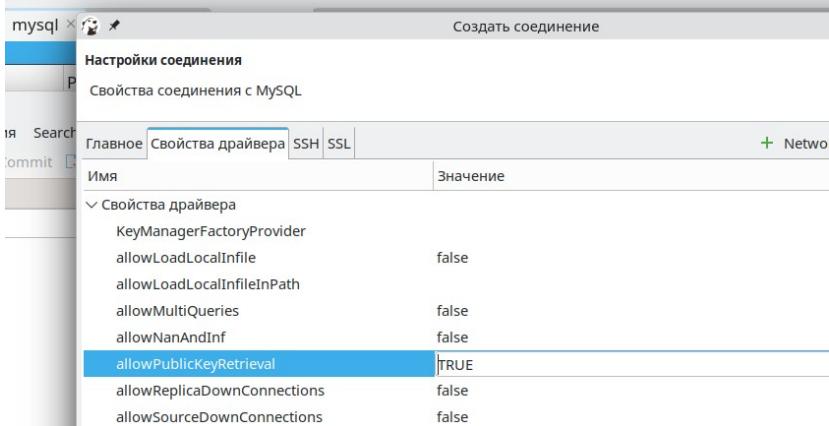
Файл `docker-compose.yaml` описывает запуск двух контейнеров: сервер базы данных `mysql` и сервер `Jupyter`, которые связаны друг с другом сетью.

Откройте консоль в папке `bigd_course_mysql_jupyter` и запустите контейнеры при помощи команды `docker compose up -d`.

При помощи консольной команды `docker compose ps` проверьте, что контейнеры корректно работают. Обратите внимание: после запуска контейнера ему потребуется некоторое время, чтобы восстановить базу из дампа. Поэтому подождите несколько минут перед попыткой соединиться с базой.

Запустите DBeaver и создайте новое соединение (меню База данных, Новое соединение). Выберите тип базы MySQL и укажите параметры подключения, которые можно найти в конфигурационном файле docker-compose.yaml. Укажите адрес хоста localhost.

В окне конфигурации соединения нажмите кнопку «Тест соединения». Вероятно, будет выдано сообщение об ошибке «Public key retrieval is not allowed». В таком случае перейдите на вкладку «Свойства драйвера» и задайте «allowPublicKeyRetrieval=TRUE»



В папке `bigd_course_mysql_jupyter` найдите папку `work`. В ней есть файл `MySQL.sql`. Откройте его в DBeaver: меню «Файл», «Найти файл по имени».

На панели инструментов DBeaver найдите выпадающий список «Текущее соединение (Ctrl+9)» и при необходимости выберите там базу «`sakila`».

Далее работа будет идти в редакторе SQL программы DBeaver. Для удобства рекомендуется включить перенос строк: меню «Редактирование», «Форматирование», «Вкл/Выкл перенос строк».

Изучите структуру базы `sakila`, которую можно найти в файле `sakila-en.a4.pdf`, находящимся в папке `bigd_course_mysql_jupyter`.

Решите задачи, которые Вы найдёте в открытом sql-файле. Вписывайте запросы и полученные ответы сразу после задач.

По окончании работы не забудьте остановить контейнеры консольной командой `docker compose down`.

Задание 2. Python + SQL

Запустите контейнеры из папки `bigd_course_mysql_jupyter`.

Перейдите в браузере по адресу `127.0.0.1:8888`. Откроется страница Jupyter.

Откройте в Jupyter файл `work/Python+SQL.ipynb` и выполните задания в нём.

По окончании работы сохраните файл, закройте Jupyter и после этого остановите контейнеры консольной командой `docker compose down`.

Задание 3. Pandas

Запустите контейнеры из папки `bigd_course_mysql_jupyter`.

Перейдите в браузере по адресу `127.0.0.1:8888`. Откроется страница Jupyter.

Откройте в Jupyter файл work/Pandas.ipynb и выполните задания в нём. В качестве дополнительного справочного материала можно использовать файл Pandas_Cheat_Sheet.pdf, который можно найти в папке bigd_course_mysql_jupyter.

По окончании работы сохраните файл, закройте Jupyter и после этого остановите контейнеры консольной командой docker compose down.

Задание 4. Pandas+SQL

Запустите контейнеры из папки bigd_course_mysql_jupyter.

Перейдите в браузере по адресу 127.0.0.1:8888. Откроется страничка Jupyter.

Откройте в Jupyter файл work/Pandas+SQL.ipynb и выполните задания в нём.

По окончании работы сохраните файл, закройте Jupyter и после этого остановите контейнеры консольной командой docker compose down.

Задание 5. ClickHouse

Скачайте и распакуйте архив bigd_course_clickhouse.zip в своей рабочей папке.

Откройте в простом текстовом редакторе, типа Блокнота, конфигурационный файл docker-compose.yaml, который находится в папке bigd_course_clickhouse. Изучите его структуру и содержание.

Запустите контейнер с сервером ClickHouse из папки bigd_course_clickhouse.

Запустите DBeaver и настройте соединение с запущенным сервером базы, Параметры подключения возьмите из конфигурационного файла docker-compose.yaml. Укажите адрес хоста localhost.

База с которой Вы соединитесь содержит единственную таблицу trips. Структура этой таблицы описана в лекциях.

В папке bigd_course_clickhouse/work найдите файл ClickHouseSQL.sql. Откройте его в DBeaver и выполните находящиеся в нём задания. Вписывайте запросы и полученные ответы сразу после задач.

По окончании работы не забудьте остановить контейнеры консольной командой docker compose down.

Задание 6. MongoDB

Скачайте и распакуйте архив bigd_course_mongodb.zip в своей рабочей папке.

Найдите в папке bigd_course_mongodb/work задания в файле MongoDB.pdf

Запустите контейнер с сервером MongoDB из папки bigd_course_mongodb.

Запустите оболочку командной строки mongosh внутри контейнера сервера базы данных. Для этого выполните в консоли команду

```
docker exec -it bigd_course_mongodb-mongo-1 mongosh
```

Работа в консоли базы, выполните задания из файла MongoDB.pdf.

По окончании работы не забудьте остановить контейнеры консольной командой docker compose down.

Задание 7. HDFS

Скачайте и распакуйте архив bigd_course_hadoop.zip в своей рабочей папке.

Откройте в ней файл с заданиями «1 - Работа с HDFS.pdf» и выполните их.

По окончании работы не забудьте остановить контейнеры консольной командой docker compose down.

Задание 8. MapReduce

После выполнения предыдущего задания у Вас в рабочей папке должна быть папка bigd_course_hadoop.

Откройте в ней файл с заданиями «2 - Работа с MapReduce.pdf» и выполните их.

По окончании работы не забудьте остановить контейнеры консольной командой docker compose down.

Задание 9. Hive

После выполнения предыдущего задания у Вас в рабочей папке должна быть папка bigd_course_hadoop.

Откройте в ней файл с заданиями «3 - Работа с Hive.pdf» и выполните их.

По окончании работы не забудьте остановить контейнеры консольной командой docker compose down.

Задание 10. PySparkLocal

Это задание выполняется на локальном Spark, без развёртывания кластера. Для этого нужно будет запустить единственный контейнер, в котором установлен локальный Spark и Jupyter для исполнения кода PySpark.

Скачайте и распакуйте в своей рабочей папке архив bigd_course_pyspark_local.zip.

Перейдите в браузере по адресу 127.0.0.1:8888. Откроется страница Jupyter.

Откройте в Jupyter файл work/PySparkLocal.ipynb и выполните задания в нём.

По окончании работы сохраните файл, закройте Jupyter и после этого остановите контейнеры консольной командой docker compose down.

Задание 11. SparkRDD

Скачайте и распакуйте архив bigd_course_spark.zip в своей рабочей папке.

Откройте в ней файл с заданиями «1 - SparkRDD.pdf» и выполните их.

По окончании работы не забудьте остановить контейнеры консольной командой docker compose down.